AI / ML Engineer · LLM · RAG · Systèmes Agentiques · MLOps

Jewin Cheng

+33 7 82 91 25 67 | jewin.cheng@gmail.com | linkedin.com/in/jewin-cheng | github.com/jewinc

PROFIL

Ingénieur IA depuis deux ans chez Malakoff Humanis, je conçois et mets en production des systèmes à forte valeur ajoutée exploitant des données non structurées — LLM, RAG et systèmes agentiques, avec une maîtrise bout-à-bout du NLP, de la vision par ordinateur et du MLOps. À l'aise pour relier la livraison technique aux besoins métier, je recherche ma prochaine mission en CDI comme AI Engineer / Data Scientist, orienté LLM et RAG.

EXPÉRIENCE PROFESSIONNELLE

Malakoff Humanis — MH Tech, Data Science — **Paris, France**

AI Engineer / Data Scientist (alternance) — 2024 – 2026 · 2 ans

- Pilotage de l'ingestion du **service RAG** d'un **chatbot assistant RH interne** : chaîne **scraping → chunking → indexation** (**BeautifulSoup**, 180 articles → 1 000 chunks) rendue autonome en job conteneurisé, **ré-ingestion incrémentale par hachage** ramenant une **ré-indexation complète de 2 h à quelques minutes**, correction d'un bug de **troncature silencieuse du LLM** — **OpenSearch** hybride (**BM25** + **k-NN**), **S3**, proxy **LiteLLM**, tests et couverture via un build d'image **Jenkins**.
- Conception et déploiement (en batch) d'un **pipeline de classification documentaire** (parsing PDF et OCR → labellisation → entraînement → inférence) atteignant **85 % de précision** sur un **corpus de 1,1 M de documents**, extrayant **200 K contrats critiques d'assurance santé** et débloquant un travail à l'arrêt depuis plusieurs années pour les gestionnaires de contrats (projet de 8 mois, 5 personnes).
- Entraînement et intégration d'un modèle de **vision par ordinateur R-CNN** dans un pipeline **NER** d'avis d'imposition (100 K avis/an) : **+7 points** de performance bout-à-bout vs la baseline QR-code-only.
- Fine-tuning de **BERT** pour la **classification hiérarchique de mails** (3 niveaux, **200+ classes feuilles**, 20 K mails/mois), **70 % de précision** en production ; revues métier hebdomadaires avec le project owner révélant cas particuliers et contournements de processus — jamais mesurables auparavant.

Laboratoire des Méthodes Formelles (LMF) — Université Paris-Saclay — **Orsay, France**

Stagiaire de recherche — Juin 2024 – Août 2024 · 3 mois

- Étude des **preuves à divulgation nulle** de Monero et **outil de visualisation** de chemins de transactions sur une base publique de transactions contaminées ; restitution à l'encadrant et à un officier en cyber criminalité.

FORMATION

Université Paris-Saclay — **Orsay, France**

Master Informatique pour la Science des Données (Master ISD) — 2024 – 2026

Université Paris-Saclay — **Orsay, France**

Licence Informatique et Mathématiques — dernière année en parcours magistère (filière sélective) — 2021 – 2024

PROJETS ACADÉMIQUES

Hackathon Gen AI 2026 — Système agentique de génération de code en extension VS Code

Paris-Saclay × Paris 8 × UQAC (équipe de 4) — 2026

- Pipeline multi-agents **LangGraph** / **LangChain** transformant un besoin utilisateur en spécifications, validation, code et configuration CI/CD, livré en **extension VS Code**.

Chatbot RAG pour la résolution de tickets

Projet école M2 (équipe de 4) — 2025

- Système RAG **Snowflake Cortex** (Agent, Search, REST API) et **LangChain / LangGraph**, déployé en **Streamlit** sur Snowflake ; **70 % de faithfulness et groundedness jugées par LLM** sur 2 000 tickets.

Assistant RAG pour la nutrition

Projet de cours M2 — chef d'équipe (5 personnes) — 2025

- Pilotage d'une **équipe de 5** sur le **feature design** (nutri-score, substitution d'ingrédients, réécriture de recettes) et coordination avec les autres chefs d'équipe ; application web conversationnelle livrée en 2 mois.

COMPÉTENCES

Programmation : Python, SQL, Java, OCaml, Rust, JavaScript / Node.js, C / C++

IA / ML : PyTorch, scikit-learn, Transformers (BERT), NER, vision par ordinateur, spaCy, NLTK, PyMuPDF, NumPy, Pandas

LLM / Agentique : LangChain, LangGraph, LiteLLM, RAG (chunking, embeddings, hybride BM25 + k-NN), multi-agents, prompt engineering, fine-tuning, évaluation LLM (faithfulness / groundedness), Snowflake Cortex

Data / MLOps : MLflow, Docker / ECR, Kubernetes, Jenkins, CI/CD, Airflow, Spark, pipelines ETL / ingestion, AWS S3, AWS OpenSearch, Dataiku

Outils : Git / GitHub / GitLab, Linux, JupyterLab, Visual Studio Code, IntelliJ IDEA, Tableau

Certifications : Dataiku Core Designer ; Dataiku ML Practitioner

Langues : Français, chinois mandarin (langues maternelles) ; anglais (TOEIC 925/990, Linguaskill 177/180, EUGLOH)